TP2 - Traitement Automatique des Langues
Représentations avec des espaces de Thèmes

Introduction

Ce TP porte sur un problème de classification de textes, visant à identifier le parti politique associé à des documents textuels (données déjà manipulées pendant le premier TP). La classification de texte est un domaine clé du TAL et a de nombreuses applications.

La manière dont les mots et les documents sont représentés est essentielle pour tout problème de classification de texte. Une approche classique consiste à représenter les documents sous forme de vecteurs de caractéristiques fondés sur la fréquence des mots qu'ils contiennent. Par exemple, la méthode TF-IDF (Term Frequency-Inverse Document Frequency), que vous avez déjà expérimentée, calcule l'importance de chaque mot en fonction de sa fréquence dans le document et de sa rareté dans l'ensemble du corpus. Cette approche est simple et souvent efficace, mais elle ne prend pas en compte les relations entre les mots et le contexte global du document.

Une alternative possible est la modélisation par espaces de thèmes. Cette approche, par exemple via le modèle Latent Dirichlet Allocation (LDA), permet de représenter un document comme une distribution de plusieurs thèmes latents. Chaque thème est lui-même une distribution de mots. Cela permet de capturer des informations plus abstraites et des régularités sémantiques qui ne sont pas visibles via une simple comptabilisation de mots. En divisant un document en thèmes, on peut mieux comprendre sa structure sémantique.

L'objectif de ce TP est surtout de travailler sur la représentation pour déterminer le parti politique associé à chaque document, en appliquant alors simplement, à la fin, un classifieur de type SVM. Dans un premier temps, vous utiliserez une représentation par sac de mots avec le calcul de TF-IDF. Ensuite, vous modéliserez les documents en utilisant une approche par espaces de thèmes LDA et comparerez les performances des deux approches. Vous serez principalement amenés à travailler avec la bibliothèque Scikit-learn (https://scikit-learn.org/stable/).

Bibliothèque Scikit-learn

Scikit-learn est une bibliothèque libre et open-source en Python dédiée à l'apprentissage automatique. Elle fournit des outils simples et efficaces pour l'analyse et le traitement des données, et est largement utilisée dans le domaine de l'apprentissage automatique et du TAL.

La bibliothèque possède de nombreux avantages, implémentant notamment un large choix d'algorithmes d'apprentissage supervisé et non supervisé (régression, classification, clustering, réduction de dimensionnalité, etc.), comme par exemple SVM, Random forest ou les k plus proches voisins, tout en étant extensible. L'autre avantage de cette bibliothèque est également, via son API, de permettre la mise en place rapide d'un pipeline complet, allant du pré-traitement des données, de leur représentation, jusque'à la résolution de tâches. Enfin, il intègre des approches classiques pour la mise en place de protocoles expérimentaux, comme la validation croisée ou l'optimisation des hyper-paramètres de méthodes.

Scikit-learn est distribué sous licence BSD, permettant un usage commercial.

Travail à faire

Votre travail va donc consister à continuer le travail initié pendant le premier TP, à savoir les données de DEFT 2009 sur des textes de débats au Parlement européen : https://madoc.univ-nantes.fr/mod/resource/view.php?id=2292403

Vous réutiliserez le code réalisé pendant le premier TP pour le pré-traitement et la préparation des données. Votre travail portera sur la tâche 3 du défi DEFT 2009. Nous nous concentrerons ici sur les données en français.

Les outils développés devront s'appuyer autant que possible sur Scikit-learn. Pour toutes les expériences, vous utiliserez le même classifieur SVM et les mêmes paramètres. L'objectif du TP est en effet d'étudier l'impact de la représentation des documents, et non de comparer différents classifieurs.

L'évaluation devra faire intervenir plusieurs métriques : accuracy, F1 macro, F1 micro, matrice de confusion, et précision/rappel par classe.

Vous déposerez une archive au **format .zip** contenant :

- le code source de votre travail. Merci de respecter les codes des questions en commentaire dans le code (ex. Question 1a, Question 1b, etc.) ;
- Un court rapport qui devra répondre aux questions posées dans le cadre de ce TP, et qui proposera un résumé des expériences menées : vous devrez avoir une partie reprenant les différentes approches développées, un tableau des résultats résumant les performances de vos systèmes, et un paragraphe décrivant ces résultats permettant de mieux les comprendre. Le meilleur résultat de la campagne en 2009 ainsi que ceux des annotateurs humains devront également figurer dans votre tableau : vous devez aussi vous comparer à ces résultats.

1. Mise en place d'un système *baseline*

Vous devez commencer par mettre en place un système baseline, c'est-à-dire un système classique servant de référence pour les expériences suivantes.

La représentation des documents sera réalisée avec TF-IDF, puis les vecteurs obtenus seront utilisés comme entrée d'un classifieur SVM.

Vous choisirez les paramètres de pré-traitement que vous jugez pertinents (par exemple : suppression des mots outils, lemmatisation, tokenisation, n-grammes, etc.). Les choix effectués devront être brièvement justifiés dans votre rapport.

Questions :

1a. Construisez le pipeline TF-IDF + SVM et évaluez-le avec les différentes métriques demandées.

1b. Analysez brièvement les résultats obtenus, notamment à partir de la matrice de confusion et des performances obtenues pour chaque classe.

2. Approche choisie par le système proposé pendant la campagne

Résumez, dans votre rapport, l'approche proposée par les participants à DEFT 2009 pour la tâche visée. Quelles sont ses forces et ses faiblesses ? Vous ne devez pas reproduire ici la méthode.

Questions :

2a. Résumez en quelques paragraphes le principe général de l'approche proposée.

2b. Identifiez ses principales forces et limites dans le contexte de la tâche considérée.

Vous ne devez pas reproduire cette méthode dans votre propre système. L'objectif est ici de comprendre le type d'approche utilisée lors de la campagne et de mettre vos résultats en perspective.

3. Représentation par espaces de thèmes

Vous allez maintenant remplacer la représentation TF-IDF par une représentation fondée sur un modèle de thèmes LDA (Latent Dirichlet Allocation).

Un corpus de textes destiné à l'apprentissage du modèle de thèmes est fourni (texte brut sans annotation). Ce corpus ne contient pas les documents du jeu de test. Il est extrait du corpus ParisParl (ici, un extrait de 15k documents) : https://zenodo.org/records/3819374

Dans un premier temps, entraînez un modèle LDA sur les données d'entraînement du corpus prévu à cet effet.

Attention : le modèle LDA doit être appris uniquement à partir des données d'entraînement. Les documents du jeu de test devront ensuite être projetés dans l'espace thématique au moyen de la transformation du modèle appris.

Chaque document sera ainsi représenté par une distribution de probabilités sur les différents thèmes. Cette représentation sera ensuite utilisée comme entrée du même classifieur SVM que précédemment.

Questions :

3a. Construisez un premier système LDA + SVM et comparez ses performances au système baseline.

3b. Expliquez brièvement les principaux hyperparamètres de LDA utilisés dans votre système, notamment :
- n_components : nombre de thèmes ;
- max_iter : nombre maximal d'itérations ;
- doc_topic_prior : paramètre contrôlant la distribution des thèmes dans les documents ;
- topic_word_prior : paramètre contrôlant la distribution des mots dans les thèmes.

3c. Faites varier au moins deux hyperparamètres, dont obligatoirement n_components. Utilisez un nombre raisonnable de valeurs et comparez les performances obtenues.

Vous pourrez par exemple étudier l'influence de :
- n_components ;

- doc_topic_prior ;
- topic_word_prior ;
- max_iter.

3d. Analysez les résultats obtenus. Discutez notamment de l'effet du nombre de thèmes sur les performances de classification.

Lorsque cela vous paraît pertinent, examinez également les thèmes obtenus par LDA afin d'identifier les types de mots qui leur sont associés.

4. Variation des approches

Pour les étudiants souhaitant aller plus loin, vous pourrez explorer une autre approche de modélisation thématique, par exemple BERTopic. Cette expérimentation est facultative et ne sera pas nécessaire pour répondre aux objectifs principaux du TP.